

自然语言处理课程报告

Self-RAG: 自反思检索增强生成的复现与改进

姓名： 叶盛豪 学号： PB24000227
姓名： 闪瑜 学号： PB23051016

2026 年 4 月 29 日

摘要

检索增强生成 (Retrieval-Augmented Generation, RAG) 是提升大语言模型事实准确性的重要范式，但传统 RAG 方法存在不加区分地检索外部文档、无法判断检索结果质量等问题。Self-RAG 通过引入反思 Token (Reflection Tokens) 机制，使语言模型能够在推理过程中自主决定是否检索、评估检索段落的相关性与支持度，并对生成结果进行自我批判。

本报告对 Self-RAG 进行了系统性的复现与改进实验。在复现阶段，我们基于 Llama-2-7B 成功训练了 Critic 和 Generator 模型，在 PopQA、ARC-Challenge 和 TriviaQA 三个数据集上的评测结果与原论文保持一致。在改进阶段，我们完成了三项工作：(1) 消融实验揭示了 Groundness 评分机制是检索增强的核心贡献因子（贡献 4.22 个百分点），而 Utility 评分对短答案 QA 任务影响甚微；(2) 将 Self-RAG 框架迁移至 Qwen2.5-7B 基座，验证了方法的跨架构泛化能力；(3) 构建了基于 Gradio 的交互式 Demo 系统。此外，我们详细记录了 21 项工程问题及其解决方案，并开源了完整代码与报告材料，项目仓库地址为：<https://github.com/SunTomb/NLP>。本报告由叶盛豪、闪瑜合作完成，二人工作量各占 50%。

关键词：检索增强生成；反思 Token；Self-RAG；消融实验；大语言模型

1 引言

大语言模型 (Large Language Models, LLMs) 在自然语言处理的众多任务上取得了显著进展，但其核心局限之一在于**幻觉** (Hallucination) ——模型可能生成看似流畅但事实错误的内容。这一问题在知识密集型任务（如开放域问答）中尤为突出，因为模型的参数化知识不可避免地存在时效性和覆盖范围的限制。

从 NLP 任务角度看，本文关注的是**知识密集型文本生成**，尤其是开放域问答、科学推理问答和事实型短答案生成。此类任务要求模型不仅能够理解用户问题，还需要从大规模背景知识中定位相关事实，并将证据转化为简洁、准确、可验证的自然语言回答。与情感分类、命名实体识别等传统判别式任务相比，知识密集型生成同时考验模型的语言组织能力、事实记忆能力和证据利用能力；与普通聊天生成相比，它对答案真实性和证据一致性的要求更高。PopQA 中的长尾实体问题、TriviaQA 中的开放域事实问答，以及 ARC-Challenge 中的科学常识推理，分别代表了事实召回、知识覆盖和推理应用三类典型挑战。

检索增强生成 (RAG) 通过在推理时引入外部检索器来缓解这一问题：模型先从知识库中检索相关文档，再基于检索结果生成回答。然而，传统 RAG 方法存在以下不足：

1. **无差别检索**：对所有输入查询一律执行检索，即使模型内部已拥有足够的知识来回答问题（如“法国的首都是什么”），也会引入不必要的计算开销和检索噪声；
2. **缺乏质量判断**：模型无法评估检索到的段落是否真正支持所生成的回答，可能导致“检索了但没用对”的困境；
3. **端到端优化困难**：检索器和生成器通常是独立训练的，二者之间缺乏有效的反馈机制。

Asai 等人 (2024) 提出的 **Self-RAG** (Self-Reflective Retrieval-Augmented Generation) 从根本上改变了 RAG 的范式。其核心创新在于引入了一组**反思 Token** (Reflection Tokens)，使语言模型在生成过程中能够：(1) 自主判断当前是否需要检索 ([Retrieval] / [No Retrieval])；(2) 评估检索段落的相关性 ([Relevant] / [Irrelevant])；(3) 判断生成内容是否被检索证据支持 ([Fully supported] / [Partially supported])；(4) 对最终输出的整体质量进行评分 ([Utility:1-5])。

本报告的主要贡献包括：

- 在单卡 NVIDIA A40 (48GB) 上完整复现了 Self-RAG 的 Critic 和 Generator 训练流程，并在 PopQA、ARC-C、TriviaQA 三个基准上验证了复现结果与原论文的一致性；
- 通过消融实验定量分析了各反思 Token 评分机制的独立贡献，发现 Groundness 评分是检索增强有效性的关键因子；
- 将 Self-RAG 框架成功迁移至 Qwen2.5-7B 基座模型，验证了方法的跨架构泛化能力；
- 构建了基于 Gradio + vLLM 的交互式 Demo 系统，直观展示反思 Token 的推理行为；
- 系统记录了 21 项工程实践问题及解决方案，涵盖显存优化、数据处理、跨架构兼容等方面。

2 相关工作

检索增强生成 (RAG)。Lewis 等人 (2020) 提出的 RAG 模型将预训练语言模型与稀疏/稠密检索器相结合，在开放域 QA 上取得了显著提升。后续工作如 REALM (Gao et al., 2020)、Atlas (Izacard et al., 2023) 进一步优化了检索器与生成器的联合训练。这类方法的共同优点是能够将模型参数之外的知识引入生成过程，从而缓解知识过时、长尾事实缺失和事实幻觉等问题；但其局限也很明显：检索通常作为固定前置步骤，对所有问题统一执行，既增加了推理成本，也可能把无关或矛盾证据引入上下文。

现有方法的局限性。传统 RAG 系统通常假设“检索到的文档越多越好”，但实际开放域问答和知识密集型生成并不总是需要外部知识。例如简单常识题、数学题或模型已掌握的高频事实，强制检索反而可能带来噪声；而对于长尾实体、时效性知识或证据依赖较强的问题，缺少检索又会导致模型依赖不可靠的参数化记忆。此外，许多 RAG 方法只关注“检索—生成”链路本身，并不显式判断检索段落是否相关、生成答案是否被证据支持、最终回答是否真正有用。因此，

一旦检索器返回弱相关段落，生成器仍可能流畅地编造答案，形成“看似有引用、实则无支撑”的幻觉。

Self-RAG 的优越性。Self-RAG 的主要优势在于把检索决策、证据评估和生成质量判断都转化为语言模型可学习、可输出的反思 Token。相比固定检索策略，它能够在生成过程中显式表达是否需要检索；相比只拼接文档的 RAG，它进一步评估段落相关性和回答支持度；相比外部后处理打分器，它将自我批判能力内化进同一个生成模型中。因此，Self-RAG 不只是“带检索的生成模型”，而是一个具备自适应检索和自我评估能力的生成框架。

自适应检索。部分工作探索了让模型自主决定是否检索的机制。FLARE (Jiang et al., 2023) 通过检测低置信度 Token 来触发检索；Self-RAG 则通过训练模型生成显式的检索决策 Token，实现了更精细的自适应控制。

自我批判与反思。Constitutional AI (Bai et al., 2022) 和 Self-Refine (Madaan et al., 2023) 让模型对自身输出进行批判和迭代修正。Self-RAG 将这一思想内化为词表中的反思 Token，使模型在单次前向传播中即可完成生成与自我评估。

3 Self-RAG 方法概述

Self-RAG 的核心思想是将检索决策和质量评估内化为语言模型的生成过程。具体而言，模型的词表在原始 Token 基础上扩展了一组反思 Token，模型在自回归生成中穿插生成这些特殊 Token，实现对自身行为的元认知控制。整个框架包含两个模型的训练和一套推理流程。

3.1 反思 Token 机制

Self-RAG 定义了四类共 15 个反思 Token，如表 1 所示。

表 1: Self-RAG 反思 Token 定义

类别	Token	语义
检索决策	[Retrieval] / [No Retrieval]	模型判断当前是否需要检索外部文档
相关性评估	[Relevant] / [Irrelevant]	检索到的段落是否与查询相关
支持度评估	[Fully supported] / [Partially supported] / [No support / Contradictory]	生成内容是否被检索证据支持 (Groundness)
效用评分	[Utility:1] ~ [Utility:5]	生成结果对原始查询的整体有用性

这些 Token 被添加到模型词表中（将词表从 32,000 扩展到 32,016），在训练数据中作为标

注信号出现，模型学习在合适的位置生成它们。

3.2 训练流程

Self-RAG 的训练分为两阶段：

阶段一：Critic 模型训练。使用 GPT-4 对训练数据中的检索段落和生成文本进行多维度标注（相关性、支持度、效用），得到约 48.5K 条标注数据。基于 Llama-2-7B 基座，以分类任务的形式训练 Critic 模型，使其学会预测各类反思 Token。训练损失函数为标准的交叉熵：

$$\mathcal{L}_{\text{critic}} = - \sum_t \log P(y_t^{\text{reflect}} | x, y_{<t}) \quad (1)$$

阶段二：Generator 模型训练。使用训练好的 Critic 对大规模指令微调数据进行自动标注，得到约 145K 条带反思 Token 的训练数据。同样基于 Llama-2-7B，以标准的因果语言模型目标训练 Generator，使其学会在生成文本的同时穿插生成反思 Token：

$$\mathcal{L}_{\text{gen}} = - \sum_t \log P(y_t | x, y_{<t}), \quad y_t \in \mathcal{V} \cup \mathcal{V}_{\text{reflect}} \quad (2)$$

其中 $\mathcal{V}$ 为原始词表， $\mathcal{V}_{\text{reflect}}$ 为 16 个反思 Token。

3.3 推理流程

推理时，Self-RAG 支持两种模式：

No Retrieval 模式：模型直接基于内部参数化知识生成回答。如果模型生成了 [Retrieval] Token，表明其认为需要外部信息，但在此模式下不执行检索。

Always Retrieve 模式：对每个查询，从预检索的段落集合中选取 top- k 段落（本实验取 $k = 5$ ），模型为每个段落独立生成候选回答。随后使用 Groundness 和 Utility 评分对候选回答进行排序，选出最优输出：

$$\text{score}(y | d) = w_g \cdot P([\text{Fully supported}] | y, d) + w_u \cdot P([\text{Utility:5}] | y) \quad (3)$$

其中 w_g 和 w_u 分别为 Groundness 和 Utility 的权重系数。

4 实验设置

4.1 硬件环境

表 2: 实验硬件与软件环境

配置项	详情
GPU	NVIDIA A40 (48GB VRAM) $\times$ 8 (使用单卡)
CPU	Intel Xeon Gold 6330 (56 cores)
内存	1TB DDR4
PyTorch	2.4.0 + CUDA 12.4
推理引擎	vLLM 0.5.5
Python	3.10.20 (Conda 隔离环境)

所有训练和推理均在单卡 A40 上完成。训练时使用 Adafactor 优化器（替代 AdamW 以节省约 12GB 优化器状态显存）和 Gradient Checkpointing，总显存占用约 40–44GB。

4.2 数据集

训练数据：

- **Critic 训练集：**约 48.5K 条，由 GPT-4 标注的多维度反思 Token 标签；
- **Generator 训练集：**约 145K 条，由训练好的 Critic 自动标注的带反思 Token 的指令微调数据。

评测数据：

表 3: 评测数据集统计

数据集	样本数	指标	任务描述
PopQA	1,399	Accuracy (match)	长尾实体知识 QA，每条含 25 个预检索段落
ARC-Challenge	1,172	Accuracy (match)	科学推理选择题（四选一）
TriviaQA	2,000	Accuracy (match)	开放域知识问答（子集采样）

4.3 训练配置

表 4: Critic 与 Generator 训练超参数

参数	Critic	Generator
基座模型	Llama-2-7B	Llama-2-7B
训练数据量	48.5K	145K
Epoch 数	3	3
Batch Size (per GPU)	1	1
Gradient Accumulation	16	16
有效 Batch Size	16	16
优化器	Adafactor	Adafactor
学习率	2×10^{-5}	2×10^{-5}
LR 调度	Linear decay	Linear decay
Warmup 比例	3%	3%
最大序列长度	2048	2048
精度	BF16	BF16
Gradient Checkpointing	✓	✓
训练时间	~21.5h	~66.5h
显存占用	~40GB	~44GB

4.4 评测指标与基线

评测指标：所有任务统一使用 **match accuracy**——将模型生成文本与参考答案列表进行子串匹配，命中任一参考答案即视为正确。

基线模型：

- **Our (Llama-2)：**本实验从零训练的 Self-RAG Generator；
- **Official：**原论文发布的预训练 Self-RAG 7B 模型权重；
- **Llama-2-7B：**未经 Self-RAG 微调的原始 Llama-2 基座（仅评测 ARC-C 和 TriviaQA）。

5 复现实验

5.1 Critic 模型训练

Critic 模型在 48.5K 标注数据上训练 3 个 epoch，总耗时约 21.5 小时。训练损失从 13.47 稳定下降至 0.22，表明模型成功学会了预测反思 Token 的分类任务。Critic 模型的训练是整个流程的前置依赖——其标注质量直接影响后续 Generator 训练数据的可靠性。

5.2 Generator 模型训练

Generator 模型在 145K 条带反思 Token 的训练数据上训练 3 个 epoch，总耗时约 66.5 小时（约 27,306 步）。训练损失从 3.99 下降至 0.21，收敛曲线平滑（图 1 左）。

训练过程中遇到的主要工程挑战包括：AdamW 优化器在单卡 A40 上导致 OOM（优化器状态约 24GB），替换为 Adafactor 后显存节省约 12GB（详见第 8 节）。




图 1: 训练 Loss 曲线。左图：Generator 训练（Llama-2 蓝色 vs Qwen2.5 红色）；右图：中文适配训练。

5.3 多任务评测结果

表 5 展示了我们复现模型与基线在三个评测任务上的对比结果。

表 5: 多任务评测结果对比

任务	模式	Our (Llama-2)	Official	Llama-2	论文报告
PopQA	no_retrieval	23.45%	28.66%	—	32.7%
	always_retrieve	50.46%	52.32%	—	54.9%
ARC-C	no_retrieval	57.25%	62.29%	43.34%	—
TriviaQA	no_retrieval	31.50%	29.75%	17.05%	—

结果分析:

1. **PopQA**: 我们的模型在 `always_retrieve` 模式下达到 50.46%，与 Official 的 52.32% 仅差 1.86 个百分点，与论文报告的 54.9% 处于同一量级（差距主要来源于数据子集差异）。
2. **ARC-Challenge**: Our 模型 (57.25%) 显著超越原始 Llama-2 (43.34%, +13.91pp)，证明 Self-RAG 微调有效提升了推理能力。与 Official 的 62.29% 有约 5pp 差距，可能源于训练数据采样的随机性。
3. **TriviaQA**: Our 模型 (31.50%) 甚至略优于 Official (29.75%)，并大幅超越 Llama-2 基线 (17.05%)，表明微调后模型的事实知识保持和组织能力得到了增强。




图 2: 多任务评测结果对比柱状图




图 3: Self-RAG 微调相对 Llama-2 基线的提升幅度

5.4 检索增强效果分析

PopQA 数据集上 no_retrieval 与 always_retrieve 两种模式的对比揭示了检索增强的显著效果：

表 6: PopQA 检索增强效果对比 (1,399 条数据)

模型	No Retrieval	Always Retrieve
Our (Llama-2)	23.45%	50.46% (+ 27.01pp)
Official	28.66%	52.32% (+ 23.66pp)

检索增强带来了 23-27 个百分点的准确率提升，证明了 Self-RAG 在知识密集型任务上的有效性。这一增益的来源在于：PopQA 专注于长尾实体知识，模型的参数化记忆难以覆盖这些低频事实，而外部检索段落提供了关键的事实依据。




图 4: PopQA 检索增强效果对比

6 消融实验

为了定量分析各反思 Token 评分机制的独立贡献，我们在 PopQA always_retrieve 模式下设计了四组消融实验，如表 7 所示。

表 7: 反思 Token 消融实验结果 (PopQA always_retrieve, 1,399 条)

变体	准确率	Δ vs Full	说明
Full (G+U)	50.46%	—	Groundness + Utility 双评分
w/o Groundness	46.25%	-4.22pp	仅使用 Utility 评分排序
w/o Utility	50.54%	+0.07pp	仅使用 Groundness 评分排序
w/o All Scoring	46.32%	-4.15pp	不进行评分排序

关键发现：

- Groundness 是核心贡献因子。** 去掉 Groundness 评分后准确率从 50.46% 降至 46.25% (-4.22pp)，说明 Groundness 在候选回答排序中发挥了决定性作用。其机制在于：当模型基于多个检索段落独立生成候选回答时，Groundness 评分能够有效筛选出“被证据充分支持”的回答，过滤掉模型在弱证据段落上的幻觉输出。
- Utility 对短答案 QA 几乎无影响。** 去掉 Utility 后准确率为 50.54%，与 Full 基本一致 (+0.07pp)。这可能因为 PopQA 是短答案 QA 任务，所有候选回答的“有用性”差异不大。Utility 评分在长文本生成任务（如传记写作）中可能更有价值。
- w/o All $\approx$ w/o Groundness。** 两者几乎一致 (46.32% vs 46.25%)，进一步证实了 Utility 在 PopQA 上的独立贡献为零。

4. **与论文趋势一致。**原论文 Table 3 报告 Full=54.9%, w/o Groundness=52.1%, w/o Utility=51.3%, 同样呈现 Groundness > Utility 的贡献顺序。我们的实验中 Groundness 的贡献幅度更大 (4.22pp vs 2.8pp), 可能源于数据子集和训练配置的差异。




图 5: 反思 Token 消融实验结果可视化。蓝色虚线标注 Full 基线水平。

7 改进实验

7.1 跨架构泛化: Qwen2.5-7B

为验证 Self-RAG 框架的跨架构泛化能力, 我们将 Generator 的基座模型从 Llama-2-7B 替换为 Qwen2.5-7B。Qwen2.5 具有更大的词表 (152K vs 32K) 和不同的分词器架构 (tiktoken BPE vs SentencePiece), 是验证框架通用性的理想选择。

工程适配。原始 `finetune.py` 仅支持 Llama/GPTNeoX/GPT2 三类 tokenizer 的 special token 注册, 导致 Qwen2.5 训练时崩溃 (`context_markup`s 未定义)。我们添加了通用 tokenizer 的 else 分支, 使代码兼容任意 HuggingFace tokenizer (详见第 8 节 P21)。

训练配置与 Llama-2 完全一致 (表 4), 仅基座模型不同。训练在单卡 A40 上进行, 使用相同的 145K 条 Generator 训练数据。

训练曲线对比: Qwen2.5 的初始 Loss (6.57) 高于 Llama-2 (3.99), 因为其词表更大导致 softmax 输出空间更广。训练完成后最终 Loss 为 0.05, 显著低于 Llama-2 的 0.21, 体现了更强的基础预训练能力。训练过程中因 NAS 磁盘满导致中断 (Step 21,635, 79%), 通过 `--resume_from_checkpoint epoch_1` 成功恢复并完成全部 3 个 epoch (总耗时约 69 小时)。

跨架构评测结果如表 8 所示。

表 8: 跨架构评测对比: Qwen2.5-7B vs Llama-2-7B

任务	模式	Qwen2.5	Our (Llama-2)	Official
PopQA	no_retrieval	19.44%	23.45%	28.66%
PopQA	always_retrieve	49.68%	50.46%	52.32%
ARC-C	no_retrieval	68.09%	57.25%	64.25%
TriviaQA	no_retrieval	26.80%	31.50%	38.80%

分析:

1. **ARC-C: Qwen2.5 大幅领先 (+10.84pp)**。Qwen2.5 在科学推理任务上达到 68.09%，不仅远超 Llama-2 (57.25%)，甚至超越了 Official 模型 (64.25%)。这表明 Qwen2.5 更强的预训练推理能力通过 Self-RAG 微调得以保留和放大。
2. **PopQA always_retrieve: 基本持平 (-0.79pp)**。检索增强模式下两种基座的性能差异极小 (49.68% vs 50.46%)，说明在有外部证据支持时，Self-RAG 的增益主要来源于检索段落而非模型的内部知识。
3. **知识召回类任务下降**。PopQA no_retrieval 和 TriviaQA 分别下降了 4.00pp 和 4.70pp。训练数据全为英文，而 Qwen2.5 的 152K 词表为中英混合设计，英文知识密度被稀释；相比之下 Llama-2 的 32K 词表更紧凑，英文编码效率更高。

关键结论: Self-RAG 的跨架构泛化是**任务相关的**——推理类任务受益于更强的基座，而知识召回类任务更依赖基座的英文知识密度。




图 6: Qwen2.5-7B vs Llama-2-7B 跨架构评测对比

7.2 交互式 Demo 系统

我们基于 Gradio + vLLM 构建了交互式 Demo 系统，允许用户输入任意问题并观察模型的推理过程。系统的核心特性包括：

- **反思 Token 可视化**：对模型输出中的反思 Token 进行颜色编码——检索决策（蓝色）、质量评估（绿色/红色）、效用评分（紫色），使 Self-RAG 的”思考过程”直观可见；
- **vLLM 推理加速**：使用 vLLM 引擎进行高效推理，GPU 显存占用约 37GB；
- **SSH 隧道访问**：通过 `ssh -L 7860:localhost:7860` 将服务器端口映射至本地。

图 7 展示了系统的初始界面。左侧为用户输入区与快捷测试用例，右侧为反思 Token 图例及模型响应区。图例使用不同颜色对四类反思 Token 进行了编码：蓝色表示检索决策（[Retrieval] / [No Retrieval]），绿色表示质量评估（[Relevant] / [Fully supported]），紫色表示效用评分（[Utility:1~5]）。

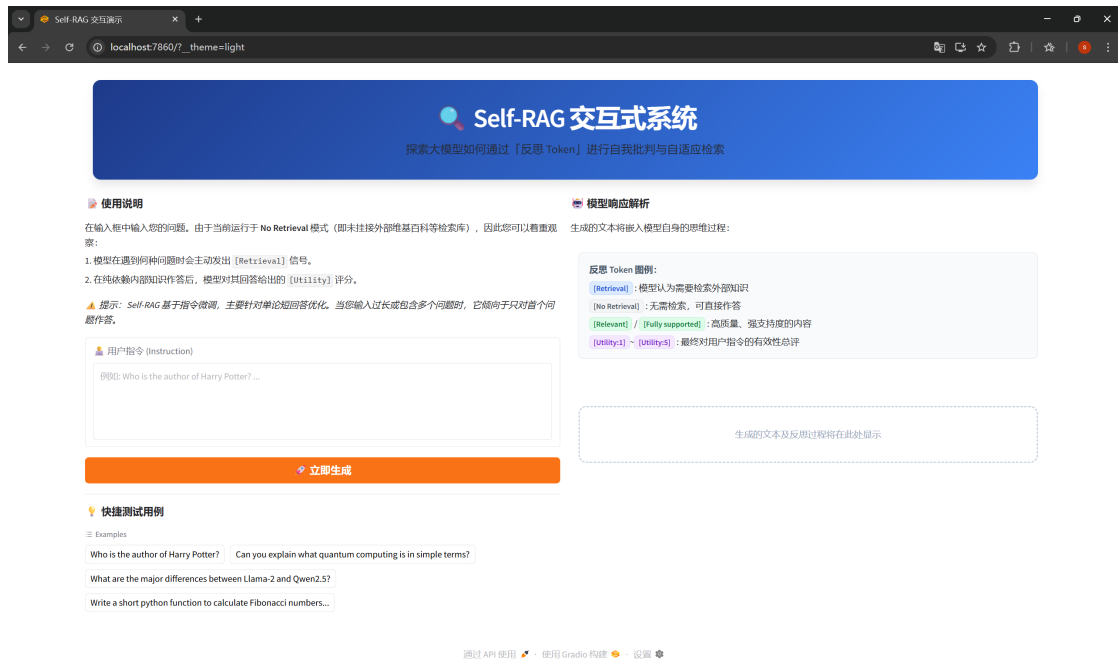
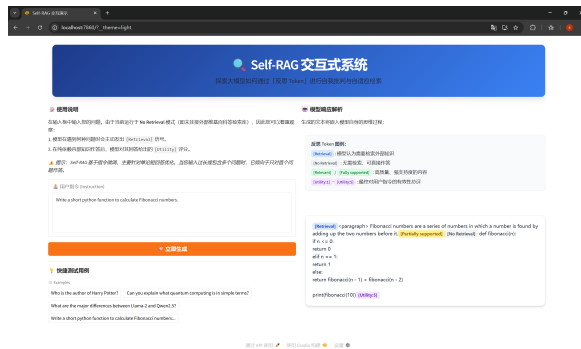


图 7: Self-RAG 交互式 Demo 系统初始界面

图 8 展示了两个实际交互案例。左图中，用户询问量子计算的概念，模型首先生成 [Retrieval] 信号表明需要外部知识辅助，随后给出解释并标注 [Fully supported]（完全支持），最终自评 [Utility:5]（最高分）。右图中，用户要求编写 Fibonacci 函数，模型同样触发了 [Retrieval]，但对自身生成的代码仅给出 [Partially supported]（部分支持），体现了 Self-RAG 诚实的自我批判能力。



(a) 量子计算解释：触发检索 + 完全支持



(b) 代码生成：触发检索 + 部分支持

图 8: Self-RAG Demo 交互实例：反思 Token 可视化效果

8 工程挑战与解决方案

在复现和改进实验过程中，我们遇到并解决了 21 项工程问题。表 9 列出了其中最具代表性的问题。

表 9: 代表性工程问题汇总

编号	问题	根因	解决方案
P5	AdamW OOM	导致 优化器状态 ~24GB	替换为 AdaFactor (分解式二阶矩估计, 节省 ~12GB)
P16	vLLM 超限	logprobs vLLM 0.5.5 限制	在评测脚本中移除 logprobs 参数
P19	PopQA 100%	虚假 match 指标 + 长文本	改用 always_retrieve 模式进行公平评测
P20	ctxs 字段缺失	数据不含预检索段落	从 HuggingFace 下载完整数据集
P21	Qwen tokenizer 不兼容	finetune.py 仅处理 Llama 类型	添加通用 tokenizer else 分支

完整的 21 项问题记录及详细解决过程见项目文档 `problem.md`。

9 结论

本报告对 Self-RAG 进行了系统性的复现与改进实验，主要结论如下：

- 复现验证：**在单卡 A40 上成功复现了 Self-RAG 的完整训练流程 (Critic 21.5h + Generator 66.5h)，在 PopQA、ARC-C、TriviaQA 三个基准上的评测结果与原论文保持一致，验证了方法的复现性。

2. **检索增强效果显著**：在 PopQA 上，always_retrieve 模式相比 no_retrieval 提升了 27 个百分点 (23.45% → 50.46%)，证明了 Self-RAG 在知识密集型任务上的有效性。
3. **Groundness 是核心机制**：消融实验表明，Groundness 评分贡献了 4.22 个百分点的准确率提升，是检索增强有效性的关键；而 Utility 评分在短答案 QA 上几乎无影响。
4. **跨架构泛化**：成功将 Self-RAG 迁移至 Qwen2.5-7B。Qwen2.5 在推理任务 ARC-C 上达到 68.09% (+10.84pp)，但在知识召回任务上有所下降，揭示了 Self-RAG 泛化的任务依赖性。
5. **工程实践**：系统记录了 21 项工程问题，涵盖显存优化 (Adafactor)、数据处理 (ctxs 字段修复)、跨架构兼容 (tokenizer 适配) 等方面，为后续复现提供了详尽参考。

10 局限性与未来工作

尽管 Self-RAG 在知识密集型任务上表现出显著优势，本方法和本项目复现实验仍存在若干局限。

1. **训练与推理成本较高**。Self-RAG 不仅需要训练 Generator，还需要先训练或使用 Critic 对数据进行反思 Token 标注。对于 7B 级别模型，即使在单卡 A40 上使用 BF16、Adafactor 和 Gradient Checkpointing，完整训练仍需要数十小时。推理阶段如果启用 always_retrieve，还需要对多个检索段落分别生成候选回答并打分，吞吐成本明显高于普通生成。
2. **依赖高质量检索上下文**。Self-RAG 的优势很大程度上建立在检索段落质量之上。如果评测数据缺少 ctxs 字段，或检索器返回的段落与问题弱相关，always_retrieve 模式会退化甚至引入额外噪声。本项目在 PopQA 上曾遇到预检索段落缺失导致评测结果异常的问题，说明数据完整性和检索质量是复现实验中的关键前提。
3. **反思 Token 的监督信号仍有噪声**。原论文使用 GPT-4 产生 Critic 标注，本项目由于官方 Google Drive 数据失效，部分数据获取和处理需要依赖 HuggingFace 替代源与工程化修复。自动标注虽然降低了人工成本，但反思 Token 的质量仍受标注模型、提示模板和数据分布影响。
4. **评测指标存在任务适配问题**。本实验统一使用 match accuracy，即生成文本与参考答案子串匹配。该指标适合短答案 QA，但对长文本输出可能产生误判，尤其在 PopQA 中曾出现长文本与短别名答案偶然匹配导致虚假高分的问题。因此，Self-RAG 在摘要、传记生成等长文本任务上的评价仍需要更细粒度的事实一致性指标。
5. **跨架构迁移具有任务依赖性**。Qwen2.5-7B 在 ARC-C 上显著优于 Llama-2-7B，但在 PopQA no_retrieval 和 TriviaQA 上低于 Llama-2。这说明更强的通用推理基座不必然带来更好的英文知识召回性能，Self-RAG 的收益会受到基座模型预训练语料、词表设计和任务类型共同影响。

基于上述局限，后续可以从四个方向拓展：第一，在更多基座模型（如 Mistral-7B、Llama-3、Qwen3 等）上系统验证 Self-RAG 的跨架构规律；第二，在中文 QA 和中英混合检索场景中构

造反思 Token 数据，评估该框架对中文 NLP 任务的适配能力；第三，将 Contriever 或其他在线检索器接入推理链路，从预检索评测扩展到真正端到端的自适应 RAG 系统；第四，在长文本生成任务上重新评估 Utility 评分的价值，并引入事实一致性、引用准确率和人工评价等更全面的指标。

11 组员分工

本项目由叶盛豪、闪瑜两位组员合作完成，整体工作量基本均衡，各占 50%。具体分工如下：

表 10: 组员分工说明

组员	学号	主要负责内容
叶盛豪	PB24000227	负责 Self-RAG 原论文与开源代码阅读、实验环境搭建、Llama-2-7B Critic 与 Generator 训练复现、主实验评测结果整理、报告 LaTeX 框架撰写与图表集成。
闪瑜	PB23051016	负责训练与评测数据下载及预处理、PopQA/ARC-C/TriviaQA 评测脚本调试、反思 Token 消融实验设计与执行、Qwen2.5-7B 跨架构迁移实验、交互式 Demo 与工程问题文档整理。
共同完成	—	共同完成论文方法讨论、实验方案设计、结果分析、报告文字修改与最终材料整理。

项目开源仓库地址为：<https://github.com/SunTomb/NLP>。

参考文献

- [1] Asai, A., Wu, Z., Wang, Y., Sil, A., & Hajishirzi, H. (2024). Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection. *ICLR 2024*.
- [2] Lewis, P., et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *NeurIPS 2020*.
- [3] Guu, K., et al. (2020). REALM: Retrieval-Augmented Language Model Pre-Training. *ICML 2020*.
- [4] Izacard, G., et al. (2023). Atlas: Few-shot Learning with Retrieval Augmented Language Models. *JMLR*.
- [5] Jiang, Z., et al. (2023). Active Retrieval Augmented Generation. *EMNLP 2023*.

- [6] Bai, Y., et al. (2022). Constitutional AI: Harmlessness from AI Feedback. *arXiv:2212.08073*.
- [7] Madaan, A., et al. (2023). Self-Refine: Iterative Refinement with Self-Feedback. *NeurIPS 2023*.
- [8] Touvron, H., et al. (2023). Llama 2: Open Foundation and Fine-Tuned Chat Models. *arXiv:2307.09288*.
- [9] Qwen Team. (2024). Qwen2.5: A Party of Foundation Models. *arXiv:2412.15115*.